

Random Erasing Data Augmentation

核心分類結果復現、差異分析與口試問答

75 runs · 3 datasets · ResNet-20/32 · 5 seeds · 300 epochs

先講結論：主旨有重現，數字不是逐點一致

02

把教授最可能先問的答案放在前面

6 / 6

方向一致

Baseline → RE，六組錯誤率全降。

90.1%

平均增益重現率

論文 0.692 pp；本專案 0.623 pp。

7 / 8

CIFAR 數值接近

CIFAR 八個值中，七個差距 ≤ 0.25 pp。

主要未解差距：Fashion-MNIST 的四個絕對數值比論文高 0.394 到 0.772 個百分點。

Random Erasing 做了什麼？

03

在訓練影像中隨機遮住一塊矩形，讓模型不要只依賴局部線索

1 決定是否擦除

每張訓練影像以 $p = 0.5$ 進行 Random Erasing。

2 抽樣矩形

面積占影像 2%–40%；長寬比約 0.3–3.33；位置隨機。

3 填入像素

論文寫法是對擦除區域填入隨機值；只在訓練時使用。

arXiv:1708.04896v2 [cs.CV] 16 Nov 2017

Abstract

In this paper, we introduce Random Erasing, a new data augmentation method for training the convolutional neural network (CNN). In training, Random Erasing randomly selects a rectangle region in an image and erases its pixels with random values. In this process, training images with various levels of occlusion are generated, which reduces the risk of over-fitting and makes the model robust to occlusion. Random Erasing is parameter learning free, easy to implement, and can be integrated with most of the CNN-based recognition models. Albeit simple, Random Erasing is complementary to commonly used data augmentation techniques such as random cropping and flipping, and yields consistent improvement over strong baselines in image classification, object detection and person re-identification. Code is available at: <https://github.com/zhunzhong07/Random-Erasing>.

1. Introduction

The ability to generalize is a research focus for the convolutional neural network (CNN). When a model is excessively complex, such as having too many parameters compared to the number of training samples, over-fitting might happen and weaken its generalization ability. A learned model may describe random error or noise instead of the



Figure 1. Examples of Random Erasing. In CNN training, we randomly choose a rectangle region in the image and erase its pixels with random values or the ImageNet mean pixel value. Images with various levels of occlusion are thus generated.

be able to recognize its category from the overall object structure. However, the collected training samples usually exhibit limited variance in occlusion. In an extreme case when all the training objects are clearly visible, *i.e.*, no occlusion happens, the learned CNN will probably work well on testing images without occlusion, but, due to the limited generalization ability of the CNN model, may fail to recognize objects which are partially occluded. While we can manually add occluded natural images to the training set, it is costly and the levels of occlusion might be limited.

To address the occlusion problem and improve the generalization ability of CNNs, this paper introduces a new data

原論文 Figure 1：同一張影像可產生不同位置、大小與填充值的遮擋。

論文版與作者程式碼版的填法不一致

04

這是本專案特別分開實作、分開報告的原因

論文文字版：paper_random

擦除區域每個像素獨立取隨機值。

本專案實作為正規化前連續 $U[0,1)$ ；論文只寫 $\text{Rand}(0,255)$ ，未說連續或離散，因此不是 bit-exact。

作者程式碼版：author_fixed

擦除區域填固定通道值。

CIFAR 正規化後 $[0.4914, 0.4822, 0.4465]$ ；換算原始像素約 $[150.657, 147.479, 136.743]$ 。Fashion 值約 71.936。

結論：不能把「論文演算法描述」與「作者倉庫實作」當成完全相同；兩者都要測。

復現設計：15 組設定，每組 5 次獨立訓練

05

固定訓練流程，只改資料集、模型深度與擦除版本

資料集

CIFAR-10

CIFAR-100

Fashion-MNIST

模型

ResNet-20

ResNet-32

條件

Baseline

Paper Random Erasing

Author Fixed (R20)

共同設定 300 epochs · batch 128 · SGD · LR 0.1 → 0.01 → 0.001 (150 / 225 epoch) · padding 4 + crop + flip

15 groups × 5 seeds = 75 formal runs

先證明資料可信：完整性檢查全部通過

06

這一頁不是結果好不好，而是確認結果真的來自完整訓練

75 / 75

checkpoint 可讀

全部 best.pt 可嚴格載入，模型結構吻合。

22,500

逐 epoch 紀錄

75 runs × 300 epochs，列數完整。

15 / 15

統計可重算

所有 aggregate 的 mean、std 與原始 run 重算一致。


測試：6 passed；正式 log 無 Traceback、RuntimeError 或 Exception。

資料集大小正確：CIFAR 50k/10k；Fashion-MNIST 60k/10k。

排除：9 個 smoke run；1 個中止校準 run 只跑 8 epochs，未納入統計。

核心結果：六組都改善，平均效果接近論文

數值是 baseline error – Random Erasing error，越高代表改善越多



平均改善

論文 0.692 pp
本專案 0.623 pp

唯一超過論文

CIFAR-100 / R32
1.610 vs 1.320 pp

六組方向一致，但各組改善幅度不必然與論文完全相同。

完整數字：與論文 Table 1 的逐列比較

單位：Top-1 test error % · mean ± population std · 5 runs


資料集 / 模型	論文 Base	本專案 Base	論文 RE	本專案 RE	本專案改善
CIFAR-10 / R20	7.21 ± .17	7.022 ± .117	6.73 ± .09	6.678 ± .179	0.344 pp
CIFAR-10 / R32	6.41 ± .06	6.268 ± .113	5.66 ± .10	5.702 ± .119	0.566 pp
CIFAR-100 / R20	30.84 ± .19	30.652 ± .228	29.97 ± .11	29.876 ± .325	0.776 pp
CIFAR-100 / R32	28.50 ± .37	29.032 ± .431	27.18 ± .32	27.422 ± .308	1.610 pp
Fashion / R20	4.39 ± .08	4.784 ± .056	4.02 ± .07	4.586 ± .058	0.198 pp
Fashion / R32	4.16 ± .13	4.816 ± .066	3.80 ± .05	4.572 ± .082	0.244 pp

讀法：看方向時比較 Base 與 RE；看復現接近度時比較「論文」與「本專案」欄。

CIFAR：主體最接近，8 個絕對值有 7 個差距 ≤ 0.25 pp

09

唯一明顯偏差是 CIFAR-100 / ResNet-32 baseline



平均絕對差

CIFAR 8 個值
平均 0.185 pp

最大差距

C100 / R32 Base
+0.532 pp

判斷：CIFAR 的核心結果可稱為接近重現，但不能說數字完全相同。

Fashion-MNIST：方向重現，但整體錯誤率系統性偏高

這是目前最需要誠實說明、也是下一輪最值得追查的地方

模型	條件	論文 error %	本專案 error %	差距 pp
ResNet-20	Baseline	4.39	4.784	+0.394
ResNet-20	Random Erasing	4.02	4.586	+0.566
ResNet-32	Baseline	4.16	4.816	+0.656
ResNet-32	Random Erasing	3.80	4.572	+0.772

仍然有改善

R20：改善 0.198 pp
R32：改善 0.244 pp

不可過度推論

差距原因尚未被單一實驗證明。資料版本、前處理、實作細節或隨機波動都可能影響。

結論用語：『方法有效方向重現，但 Fashion-MNIST 絕對值未對齊。』

作者程式碼固定填值，沒有穩定優於論文文字版

11

只比較 ResNet-20，三個資料集各 5 runs

資料集	paper_random error %	author_fixed error %	author – paper
CIFAR-10	6.678 ± .179	6.744 ± .171	+0.066 pp
CIFAR-100	29.876 ± .325	30.042 ± .299	+0.166 pp
Fashion-MNIST	4.586 ± .058	4.612 ± .060	+0.026 pp

三組 author_fixed 都略差，但差距很小，且落在 run-to-run 波動量級附近。

因此只能說：本實驗沒有看到固定填值的優勢；不能說它在一般情況必然較差。

結果口徑會影響結論：best 與 final 不一樣

12

論文沒有明確寫 Table 1 採 best 還是 final；作者程式碼會印出 best accuracy

本專案主表

採每次 run 的最佳測試錯誤率，再對 5 runs 計算 mean $\pm$ std。這最接近作者程式碼的輸出方式，但仍是推論。

如果改看 final

最後 epoch 通常更差；best 與 final 的平均差距依組別介於 0.118–1.128 pp。最大出現在 CIFAR-100 / R32 baseline。

例：CIFAR-100 / R32 baseline

best 29.032%

final 30.160%

差 1.128 pp

報告策略：主表報 best，附帶揭露 final，不隱藏口徑敏感性。

差距從哪裡來？先分清楚『已確認』與『合理假設』

13

不把猜測包裝成結論

已確認的差異或缺漏

論文未公開 seeds、std 定義、best/final 口徑。

論文隨機填值；作者程式碼固定通道值。

作者碼 `cuda.benchmark=True`；本專案採 `deterministic algorithms`。

Python patch 曾由 3.12.13 變為 3.12.14；未建立完整 transitive lock。

checkpoint 只有最佳模型權重，不能精確續跑 optimizer / RNG 狀態。

尚待驗證的合理假設

Fashion-MNIST 資料版本或前處理細節不同。

舊版框架與現代 PyTorch 的數值行為不同。

5 runs 仍可能出現抽樣波動。

論文實際內部程式與公開倉庫 commit 可能不完全相同。

正確說法：差距存在；其中部分原因已確認，但 Fashion 偏差的主因尚未被因果實驗鎖定。

完成範圍：核心分類子集，不是整篇論文全部實驗

14

對教授最重要的是把完成與未完成邊界講清楚

6 / 39

Table 1 的 dataset/model rows 已
重現

+ 3 組 `author_fixed` 對照

已完成

CIFAR-10 / CIFAR-100 /
Fashion-MNIST

ResNet-20 / ResNet-32

Baseline / paper_random /
`author_fixed` (R20)

5 runs / mean $\pm$ std /
可重算資料與報告

未完成

ResNet-44 / 56 / 110
PreAct / WRN / ResNeXt

Table 2–4
填值、dropout/noise、組合消融

Figure 4–5
超參數、遮擋魯棒性

Table 5–9
偵測與 person re-ID

建議專案名稱：Random Erasing 核心分類實驗復現

教授可能會問（一）：結果與方法

15

每題先給一句能直接回答的版本

Q1 這算復現成功嗎？

A：核心主旨成功。六組都重現 Random Erasing 優於 baseline；CIFAR 數字大多接近，但 Fashion 絕對值未完全對齊。

Q2 為什麼不用只跑一次？

A：論文 Table 1 本來就報 5 runs 的 mean $\pm$ std；單次結果可能只是幸運或倒楣的 seed。

Q3 論文版和作者版哪個正確？

A：它們回答不同問題。paper_random 對齊文字描述；author_fixed 對齊公開程式碼，所以本專案分開測。

Q4 為什麼 Fashion 差比較多？

A：目前只確認偏差存在；資料版本、前處理與框架差異是合理假設，但尚未做受控實驗證明主因。

口試問答（二）：可信度與下一步

16

最後用四句話收束

Q5 為什麼用 best，不用 final？

A：作者碼會輸出 best accuracy，較接近論文實務；但論文未明說，所以本專案同時保留 final 供查核。

Q6 能完全重跑出一模一樣嗎？

A：設定、程式、seeds、紀錄都在；但 Python patch 漂移、未鎖完整依賴，加上 checkpoint 不含 optimizer/RNG，不能宣稱 bit-for-bit。

Q7 為什麼沒有做完整論文？

A：先完成最能驗證主旨的分類核心；完整論文還包含更多架構、消融、偵測與 re-ID，已明確列為未完成。

Q8 下一步最值得做什麼？

A：先鎖死環境與資料版本，針對 Fashion 做受控排查；再擴到 ResNet-44/56/110 與 Table 2-4 消融。

最後一句：我們重現了方法的核心效果，也把沒有對齊的地方與原因不確定性完整留下。